

# Проект-ДЗ по Эксплуатации

---

В данном проекте вы выполните комплексное домашнее задание по подготовке, оптимизации и развертыванию модели машинного обучения с использованием современных инструментов. Цель проекта – освоить процессы обучения, конвертации, оптимизации и интеграции моделей в продакшн-среду с применением Triton Inference Server, Docker и микросервисной архитектуры.

---

## Задачи проекта

### 1. Обучение модели

- Обучите самописную модель на базе **Torch** или **TensorFlow**.
- Используйте стандартные слои, избегая кастомных решений.

### 2. Конвертация в ONNX

- Экспортируйте обученную модель в формат **ONNX**.

### 3. (Опционально) Конвертация в TensorRT (TRT)

- При необходимости, конвертируйте модель в формат **TensorRT** для повышения производительности инференса.

### 4. Оптимизация модели средствами Torch/TensorFlow

- Примените встроенные методы оптимизации (например, quantization или pruning) для улучшения эффективности модели.

### 5. Оптимизация модели инструментами ONNX и (опционально) TRT

- Используйте оптимизирующие инструменты для ONNX (например, ONNX Runtime) для повышения производительности.
- (Опционально) Оптимизируйте модель в формате TensorRT.

### 6. Разработка микросервиса предобработки данных

- Спроектируйте микросервис для предобработки данных, необходимых для работы вашей модели.
- Реализуйте сервис с использованием **Flask**, **FastAPI** или другого подходящего фреймворка.
- Оформите микросервис в виде **Docker-контейнера**.

### 7. Развёртывание моделей с помощью Triton Inference Server

- Запустите **Triton Inference Server**.
- Задеплойте следующие версии модели:
  - Оригинальная модель.
  - Оптимизированная модель (на базе Torch/TensorFlow).
  - Модель в формате ONNX.
  - Оптимизированная модель ONNX.

- (Опционально) Модель в формате TRT.

## 8. Настройка мониторинга метрик

- Настройте сбор и визуализацию метрик с помощью **Grafana** и **Prometheus**.
- Обеспечьте мониторинг как для Triton Inference Server, так и для микросервиса предобработки.

## 9. Оркестрация сервисов с помощью docker-compose

- Поднимите весь стек сервисов через **docker-compose**, включающий:
  - Микросервис предобработки данных.
  - Triton Inference Server.
  - Систему мониторинга (Prometheus и Grafana).

## 10. Тестирование и формирование отчёта

- Проведите тестирование всех версий модели, отправляя запросы на инференс.
- Соберите логи работы сервисов.
- Сформируйте итоговый файл с отчётом, включающим результаты тестирования, собранные логи и анализ производительности.